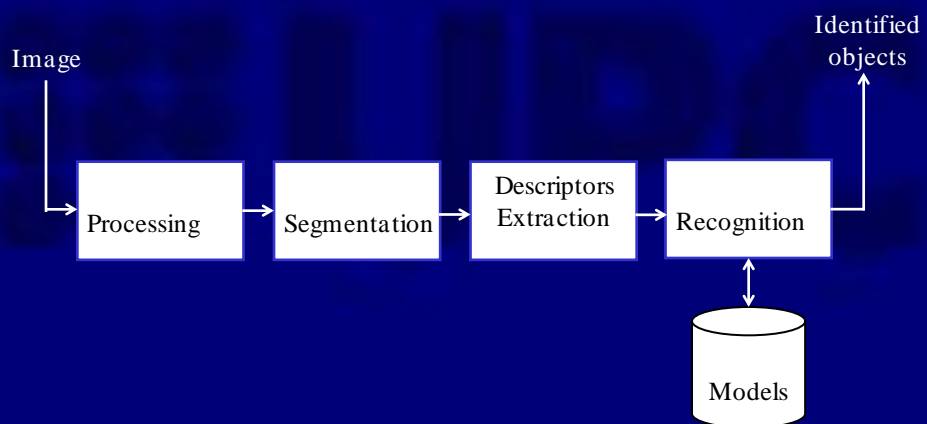
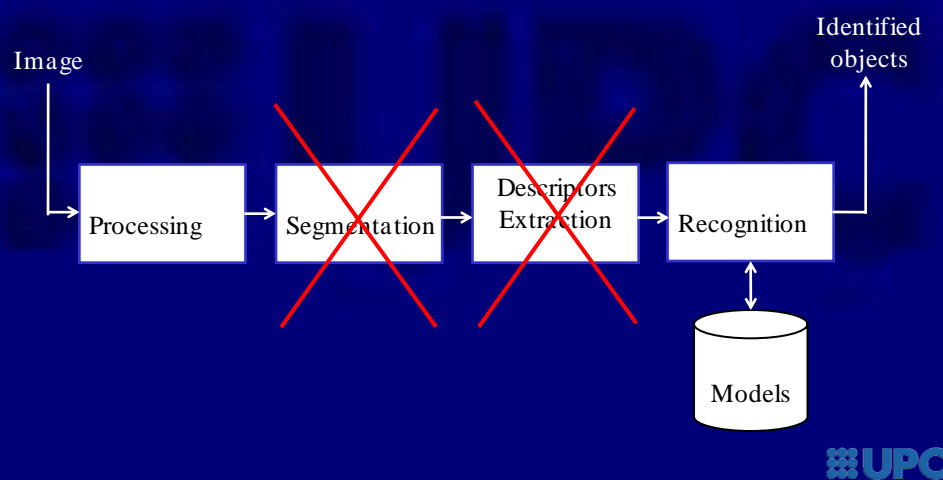


## Local Features

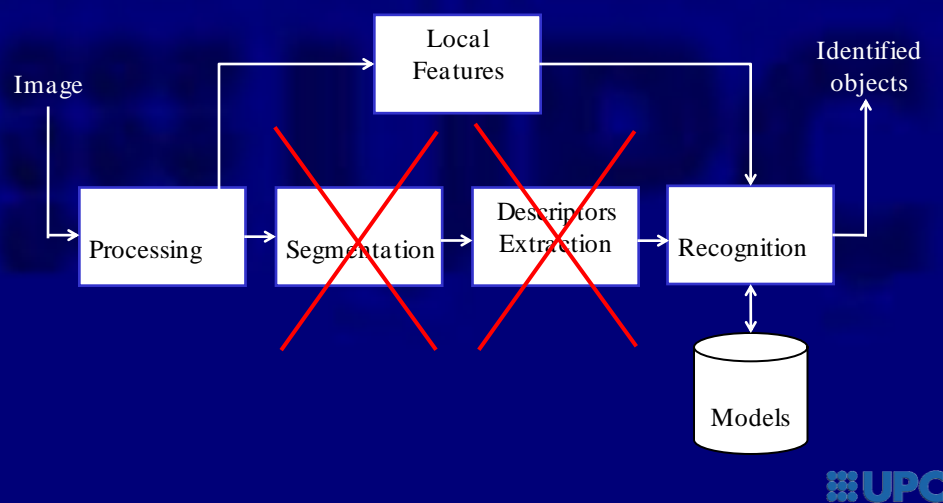
## A computer vision system



# A computer vision system



# A computer vision system



## Local Features

- Les característiques globals són sensibles al soroll i les oclusions.
- L'alternativa és usar característiques locals:
  - Si algunes característiques queden ocluídes, l'objecte potser es podrà identificar a partir d'altres característiques que siguin visibles.

### Corners are Simple Features


Can you see common feature point between the two images?



## Invariant local features

Buscar característiques que siguin invariants a transformacions diverses:

- geometric invariance: translació, rotació, escala...
- photometric invariance: il·luminació, color...



## Features "bones"

- Discriminatives (Saliency)

Han de ser significativament diferents i distingibles d'altres features properes.

- Repetitivitat

S'han de poder localitzar en imatges diferents, encara que aquestes presentin transformacions.

- Compactes

Poques dades, molta informació. Eficiència computacional

# Aplicacions


- Image alignment and stitching
- Image retrieval
- Motion tracking
- Robot navigation
- Face detection
- Object recognition
- Gesture recognition
- Human action understanding
- Biometric identification

## Aplicacions. Exemples

Image Stitching (to generate panorama)



## Aplicacions. Exemples



## Local Features

- Histogrames
- Transformada de Hough
- Vèrtexos
- Scale Invariant Feature transform (SIFT)
- Haar Features (face detection)

# Histogrames



## Histogrames de color



- Els histogrames són un tipus de descriptor basats en aparença
- El color és invariant a transformacions geomètriques
- El color és una característica local. Està definit per cada píxel
- Usarem l'histograma de color com una descripció estadística d'una regió o objecte
- Al ser un descriptor local, pot ser robust a oclusions



# Histograms de color

➤ Colour histograms are colour statistics

- Here, RGB as an example
- Given: tristimulus R, G, B for each pixel
- Compute a 3D histogram
- $h(R, G, B) = \#(\text{pixels with colour } (R, G, B))$



# Histograms de color

## Colour Normalization

➤ One component of the 3D colour space is intensity

- If a colour vector is multiplied by a scalar, the intensity changes but not the colour itself.
- This means colours can be normalized by the intensity.
- Note: intensity is given by  $I = (R + G + B)/3$
- Chromatic representation:

$$r = \frac{R}{R + G + B} \quad g = \frac{G}{R + G + B} \quad b = \frac{B}{R + G + B}$$

Since  $r + g + b = 1$ , only 2 parameters are needed to represent colour (knowing  $r$  and  $g$ , we can deduce  $b = 1 - r - g$ ).

⇒ Can compute colour histogram using  $r$ ,  $g$ , and  $b$  instead.

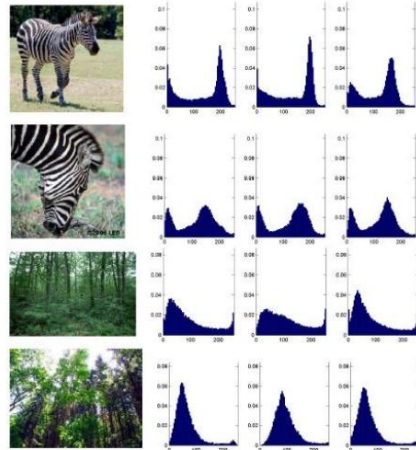


# Descriptors basats en histogrames


## Object Recognition based on Colour Histograms

### Colour histograms

- are discrete approximation of the colour distribution of an image.
- contain no spatial information  $\Rightarrow$  invariant to translation, scale, and rotation



# Descriptors basats en histogrames



# Object recognition using histograms

## Simple algorithm


1. Build a set of histograms  $H = \{h_i\}$  for each known object.
  - More exactly, for each view of each object.
2. Build a histogram  $h_t$  for the test image.
3. Compare  $h_t$  with each  $h_i \in H$  using a suitable histogram comparison measure.
4. Select the object with the best matching score;  
or reject the test image if no object is similar enough.

This is known as the “nearest-neighbour” strategy.





# Object recognition using histograms

## Histogram Comparison with Multiple Training Views



Test image





⇒ Need a good comparison measure for colour histograms !



# Comparació d'histogrames

## What is a Good Comparison Measure?

⤵ How to define matching cost?




# Comparació d'histogrames

## Euclidean distance ( $L_2$ norm)

$$d(q, v) = \sum_i (q_i - v_i)^2$$

⤵ Motivation of the Euclidean distance:

- Focuses on the differences between the histograms.
- Interpretation: distance in the feature space.
- Range:  $[0, \infty)$ .
- All cells are weighted equally.
- Not very robust to outliers !




# Comparació d'histogrames

Chi-Square distance:

$$d(q, v) = \sum_i \frac{(q_i - v_i)^2}{q_i + v_i}$$

↳ Motivation of the  $\chi^2$  distance:

- Statistical background
- Test if two distributions are different.
- Possible to compute a significance score.
- Range:  $[0, \infty)$ .
- Cells are not weighted equally !
- More robust to outliers than the Euclidean distance, if the histograms contain enough observations...




# Comparació d'histogrames

↳ Which measure is the best?

- It depends on the application
- Euclidean distance is often not robust enough.
- Generally,  $\chi^2$  distance gives good performance for histograms
- KL/Jeffreys divergence works well sometimes, but is expensive
- EMD is the most powerful, but also very expensive.

## Exemple: image retrieval

- The image retrieval problem concerns the retrieval of those images in a database that best match a query image.



L2 distance



Jeffrey divergence



$\chi^2$  distance




Earth Movers Distance




## Histogrammes d'orientacions

Idea: Podem descriure localment els objectes usant les direccions dels gradients. No cal localitzar els contorns, només saber la distribució de les seves orientacions



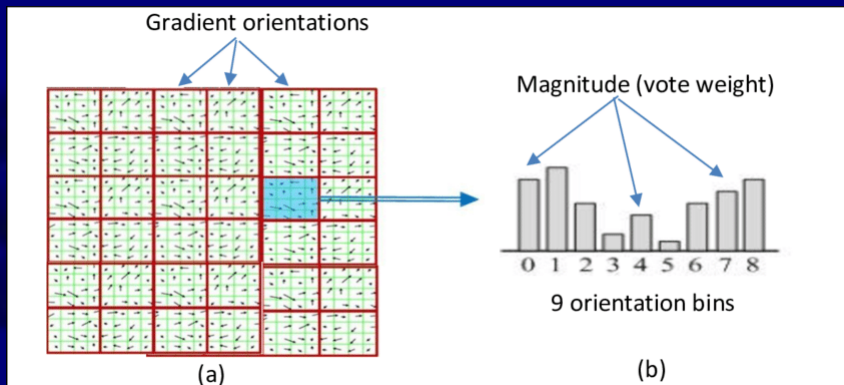
Representació lineal



Representació cíclica



## Histogrames d'orientacions



Múltiples subimatges - Múltiples histogrames



## HOGs (Histograms of Oriented Gradients)

- Dalal-Triggs, 2005
- Divide image into small sub-images: "cells"
- Accumulate a histogram of edge orientations within that cell
- The combined histogram entries are used as the feature vector describing the object
- To provide better illumination invariance (lighting, shadows, etc.) normalize the cells across larger regions incorporating multiple cells: "blocks"




## HOGs . Detecció de persones

1. Descriure cada mostra usant un HOG template



2. Entrenar una SVM com a classificador



Code available: <http://pascal.inrialpes.fr/soft/olt/> 

## HOGs . Detecció de persones

Milers de mostres positives

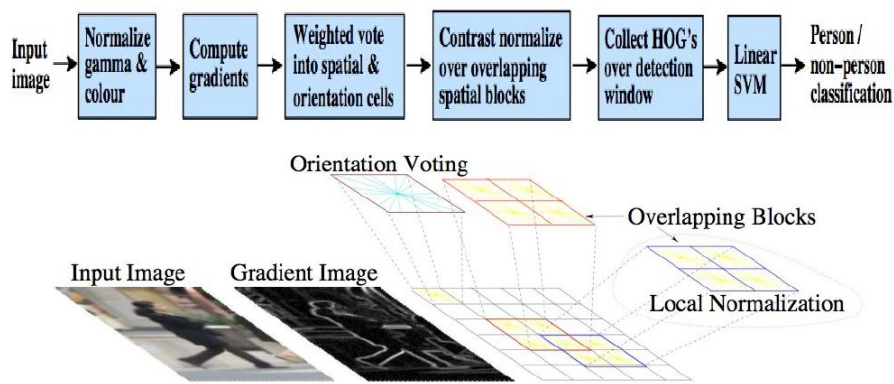


I milions de negatives

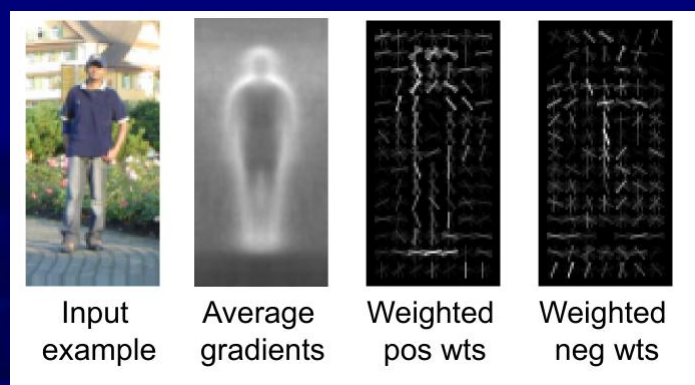


# HOGs . Detecció de persones

A worked example: Dalal and Triggs CVPR'05



# HOGs . Detecció de persones




Most important cues are head, shoulder, leg silhouettes

Vertical gradients inside a person are counted as negative





## Applications to Other Classes




M. Everingham et al. *The 2005 PASCAL Visual Object Classes Challenge*. Proceedings of the PASCAL Challenge Workshop, 2006. 25

Transformada de Hough

## Transformada de Hough

- Dissenyada originalment per a la detecció de rectes
- Molt robusta a soroll, imperfeccions i oclusions
- Cada recta en la imatge original es transforma en una punt en l'espai de Hough
- Aquest punt ve determinat per les coordenades  $(m, b)$  de la recta




#UPC

## Mapejat en l'espai de Hough

- Donat un píxel  $(x_0, y_0)$ , quantes rectes hi passen?

Resposta: totes les que satisfan l'equació  $y_0 = mx_0 + b$   
(això és una recta en l'espai de Hough)



#UPC


## Mapejat en l'espai de Hough

- On es mapeja la recta que passa pels píxels  $(x_0, y_0)$  i  $(x_1, y_1)$  en l'espai de Hough?

Resposta: En la intersecció de les rectes


$$b = -x_0 m + y_0$$

$$b = -x_1 m + y_1$$



## Mapejat en l'espai de Hough

- Podem implementar l'espai de Hough com una taula 2D d'acumuladors
- La presència de molts píxels alineats en la imatge original (una recta) es traduirà com un pic en la taula de Hough
- La transformada de Hough no és res més que un sistema de votació



## Transformada de Hough. Algorisme

1. Crear una matriu de Hough (m,b) i dimensionar-la.
2. Cada posició de la matriu és un acumulador. Posar-los tots a 0.
3. Per a cada píxel (x,y) de la imatge d'entrada (imatge de contorns), incrementar les posicions de la matriu (m,b) que satisfan l'equació.
4. Els màxims de la matriu (m,b) es corresponen a la presència de rectes en la imatge.

- Si hi ha diverses rectes a la imatge, tindrem diversos pics a la matriu.



## Dimensions de la taula de Hough


-Problema: afitar m i b.

-Solució: S'usa la forma polar de la recta:

$$\rho = x \cos(\theta) + y \sin(\theta)$$

- ara els punts (x,y) queden mapejats com funcions sinusoidals en l'espai (ρ,θ).

- ρ representa la llargada del vector normal desde l'origen de la imatge a la recta i θ la seva direcció



# Taula de Hough ( $\rho, \theta$ )






Image space





Votes

(Horizontal axis is  $\theta$ , vertical is  $\rho$ )

## Exemple




## Exemple



#UPC

## Exemple



#UPC

## Efectes del soroll

- Els pics a la taula de Hough no són fàcils de localitzar




Image space

Hough parameter space



## Transformada de Hough. Implementació

- Resolució de la taula. Quantes caselles? De quina mida?

Si les fem massa grans, rectes diferents incrementaran el mateix acumulador

Si les fem massa petites, es fraccionaran rectes

- Mai tindrem l'acumulació en una única casella. Això és per culpa del soroll en la imatge i la discretització de la taula de Hough.



Cal considerar els pics molts propers com a una única recta.  
Solucions: non-maxima supression, filtratge de la taula...

- Treballem només amb píxels rellevants. Aquells que tenen un gradient important



## Hough transform speed-up

- Coneixem la direcció del contorn (podem disposar d'aquesta informació. És la direcció del gradient)



- Podem fixar  $\theta$  en la taula de Hough i incrementar un únic acumulador.



## Speeded-up algorithm

1. Per a la imatge d'entrada, obtenir mòdul ( $G$ ) i direcció ( $\alpha$ ) del gradient.
2. Crear la taula de Hough. Serà una matriu 2D d'acumuladors  $H(\rho, \theta)$ . Cal dimensionar-la correctament
3. Inicialitzar tots es acumuladors a 0
4. per a cada pixel  $G(x,y) > \text{Thresh}$  /\* gradient prou gran \*/  
{  
     $\theta = \alpha(x,y)$  /\* direcció del gradient \*/  
     $\rho = x \cos\theta + y \sin\theta$   
    incrementar  $H(\rho, \theta)$   
}
5. Buscar màxims locals a  $H(\rho, \theta)$





## Transformada de Hough per a corbes

- La transformada de Hough es pot usar per a trobar qualsevol tipus de corba que es pugui expressar en forma paramètrica

$$y = f(x_1, x_2, \dots, x_n)$$

-  $x_1, x_2, \dots, x_n$  serien els paràmetres de l'espai de Hough

- Si  $n$  és gran, la dimensió de la matriu de Hough és també gran i la complexitat es dispara.

**Curse of dimensionality !!**



## Transformada de Hough per a trobar cercles

### **Finding Circles by Hough Transform**

↘ Equation of Circle:

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

↘ If radius is known: (2D Hough Space)

- Accumulator Array  $A(a, b)$


↘ If radius is not known: 3D Hough Space!

- Use Accumulator array  $A(a, b, r)$



## Example

### Finding Coins



Note that because the quarters and penny are different sizes, a different Hough transform (with separate accumulators) was used for each circle size.

